VERİ TÜRLERİ VE KAYNAKLARI

HAFTA 3

GİRİŞ

Veri analitiği sürecinin temeli, kullanılan verinin türü ve kaynağının doğru tanımlanmasına dayanır. Farklı veri türleri, farklı analiz yöntemleri ve araçları gerektirir; bu nedenle verinin yapısal özelliklerini bilmek, analitik sürecin yönünü belirler. Günümüzde veriler yalnızca tablolar ve sayılarla sınırlı değildir; metinler, görseller, sensör çıktıları ve sosyal medya etkileşimleri de analiz edilebilir niteliktedir. Bu çeşitlilik, veri biliminin hem kapsamını genişletmiş hem de analiz süreçlerini daha dinamik hâle getirmiştir.

Veri kaynakları ise analitik süreçte bilginin beslendiği kanalları temsil eder. Bu kaynaklar kurum içi sistemlerden, kamuya açık veri tabanlarından, sosyal medya platformlarından veya akıllı cihazlardan gelebilir. Veri kaynaklarının güvenilirlik, doğruluk ve erişilebilirlik açısından farklılık göstermesi nedeniyle, analistin veri seçiminde yüksek düzeyde farkındalığa sahip olması büyük önem taşır. Sonuç olarak, veri türleri ve kaynakları arasındaki doğru eşleşme, analitik sürecin kalitesini ve elde edilecek içgörünün güvenilirliğini doğrudan belirler.

TEMEL VERİ TÜRLERİ

Veri kümeleri birçok yönden farklılık gösterir. Örneğin, veri nesnelerini tanımlamak için kullanılan öznitelikler nicel veya nitel olmak üzere farklı türlerde olabilir ve veri kümelerinin kendine özgü özellikleri olabilir; örneğin, bazı veri kümeleri zaman serileri veya birbirleriyle açık ilişkileri olan nesneler içerir. Şaşırtıcı olmayan bir şekilde, veri türü, verileri analiz etmek için hangi araç ve tekniklerin kullanılabileceğini belirler. Dahası, veri analitiği ve madenciliği alanındaki yeni araştırmalar genellikle yeni uygulama alanlarına uyum sağlama ihtiyacından kaynaklanır.

Bu nedenle veri türlerinin doğru biçimde sınıflandırılması, analitik sürecin başarısı açısından kritik öneme sahiptir. Her veri türü farklı depolama yapıları, ön işleme yöntemleri ve analiz algoritmaları gerektirir. Örneğin, yapısal veriler istatistiksel yöntemlerle kolayca çözümlenebilirken, metin veya ağ verileri daha karmaşık modelleme ve örüntü tanıma teknikleri gerektirir. Ayrıca günümüzde veri kaynaklarının çeşitlenmesiyle birlikte, analistler artık yalnızca veriyi anlamakla değil, verinin bağlamını ve ilişkilerini doğru yorumlamakla yükümlüdür.

İLİŞKİSEL SINIFLANDIRMA

İlişkisel sınıflandırma, veriler arasındaki yapısal ve ilişkisel bağları dikkate alarak yapılan sınıflandırma yöntemidir. Bu yöntemde, sadece bireysel özellikler değil, veriler arasındaki bağlantılar da analiz edilir. Özellikle sosyal ağlar, biyolojik ağlar ve metin verileri gibi bağlı verilerde kullanılır. Geleneksel sınıflandırma yöntemlerinin yetersiz kaldığı durumlarda daha doğru sonuçlar sağlayabilir. Bu sayede daha karmaşık yapılar içerisindeki desenler daha etkili bir şekilde ortaya konur.

İlişkisel sınıflandırma, kullanıcıların etkileşimlerini temel alarak öneri sistemlerinde sıkça uygulanır. Örneğin, bir kullanıcının bağlantılı olduğu diğer kullanıcıların tercihleri sınıflandırma sürecini etkileyebilir. Bu yöntem, ilişkili verilerden anlam çıkarmada yüksek performans gösterir. Veriler arası bağımlılıkların modele dâhil edilmesi genellikle doğruluk oranını artırır. Ayrıca, ağ yapısındaki değişimlere daha duyarlı analizler yapılmasına imkân tanır.

BAĞIMLILIK TEMELLİ OLMAYAN VERİLER

Bağımlılık Temelli Olmayan Veriler, veri nesneleri arasında zaman, sıra veya mekânsal ilişki bulunmayan, her gözlemin bağımsız değerlendirildiği veri türleridir. Genellikle müşteri kayıtları, anket sonuçları veya finansal göstergeler gibi çok boyutlu tablolarda karşımıza çıkar. Bu yapı, istatistiksel analizlerin ve makine öğrenmesi yöntemlerinin uygulanmasını kolaylaştırır. Veriler genellikle sayısal, kategorik veya karma nitelikli özniteliklerden oluşur ve veri tabanlarında kolayca saklanabilir. Analiz sürecinde doğru değişken seçimi anlamlı sonuçlar elde etmek için kritik öneme sahiptir. Sonuç olarak, bağımlılık temelli olmayan veriler veri analitiği ve madenciliğinin temelini oluşturur.

NİCEL ÇOK BOYUTLU VERİLER (QUANTITATIVE MULTIDIMENSIONAL DATA)

Nicel Çok Boyutlu Veriler, ölçülebilir ve sayısal değerlerle ifade edilen, birden fazla özelliğe (boyuta) sahip veri türleridir. Her boyut, bir nesnenin belirli bir niteliğini temsil eder ve bu boyutlar birlikte analiz edildiğinde çok değişkenli istatistiksel yapı ortaya çıkar. Bu tür veriler genellikle düzenli matris veya tablo biçiminde saklanır ve sayısal işlemlere uygun oldukları için analizleri kolaydır. Veriler arasındaki ilişkiler regresyon, kümeleme veya korelasyon analizleriyle incelenebilir. Örneğin, bir müşteri veri setinde "yaş", "gelir" ve "harcama puanı" gibi ölçülebilir değişkenler nicel çok boyutlu verilere örnektir.

- **Sayısal Doğa:** Veriler ölçülebilir ve aritmetik işlemlere uygundur.
- **Çok Boyutluluk:** Her gözlem birden fazla değişken (boyut) içerir.
- **Analiz Kolaylığı:** Matematiksel ve istatistiksel yöntemlerle doğrudan analiz edilebilir.
- **Temsili Yapı:** Genellikle matris veya veri tablosu şeklinde düzenlenir.
- **Kullanım Alanları:** Finansal analiz, mühendislik ölçümleri, pazarlama segmentasyonu, bilimsel araştırmalar.

KATEGORİK VE KARMA NİTELİKLİ VERİLER (CATEGORICAL AND MIXED ATTRIBUTE DATA)

Kategorik ve Karma Nitelikli Veriler, sayısal olmayan, belirli sınıflar veya etiketlerle tanımlanan veri türlerini ifade eder. Kategorik veriler, niteliksel özellikleri temsil ederken; karma nitelikli veriler hem kategorik hem de sayısal değişkenleri aynı veri kümesinde barındırır. Bu tür veriler genellikle sınıflandırma, karşılaştırma ve örüntü tanıma analizlerinde kullanılır. Kategorik veriler doğrudan sayısal işlem görmez, ancak analiz için kodlanarak sayısallaştırılabilir. Örneğin, bir müşteri veri tabanında "cinsiyet (kategorik)" ve "yaş (sayısal)" değişkenlerinin birlikte bulunması karma nitelikli veriye örnektir.

- **Sınıflandırılmış Yapı:** Veriler, belirli etiketler veya kategoriler hâlinde tanımlanır.
- **Sayısal Olmama:** Doğrudan aritmetik işlemlere uygun değildir; genellikle kodlama gerektirir.
- **Karma Tür Desteği:** Sayısal ve kategorik öznitelikler aynı veri kümesinde yer alabilir.
- **Analiz Yöntemleri:** Karar ağaçları, lojistik regresyon, kümeleme ve sınıflandırma analizlerinde sıkça kullanılır.
- **Kullanım Alanları:** Sosyolojik araştırmalar, müşteri segmentasyonu, anket verileri, sağlık kayıtları.

İKİLİ VE KÜME VERİLERİ (BINARY AND SET DATA)

İkili ve Küme Verileri, her bir özniteliğin yalnızca iki olasılığa sahip olduğu veya nesnelerin birden fazla özelliği aynı anda barındırdığı veri türlerini kapsar. İkili veriler genellikle 0/1, var/yok veya doğru/yanlış biçiminde ifade edilirken; küme verileri, bir nesnenin birden fazla kategoriye veya öğeye aynı anda ait olabildiği durumları temsil eder. Bu veri türü, örüntü bulma, ilişki analizi ve birliktelik kuralları gibi alanlarda sıklıkla kullanılır. Analiz sürecinde veriler genellikle matris biçiminde gösterilir ve her sütun bir özelliği, her satır bir nesneyi temsil eder. Örneğin, bir market sepeti analizinde "ekmek, süt, yumurta" gibi ürünlerin bir müşterinin alışverişinde yer alıp almadığı bilgisi ikili ve küme verisi biçiminde işlenir.

- **İkili Doğa:** Her öznitelik yalnızca iki değerden birini alır (ör. 0/1).
- **Çoklu Özellik İlişkisi:** Nesneler birden fazla öğeye veya kategoriye aynı anda ait olabilir.
- **Basit Kodlama:** Veriler genellikle matris veya gösterim tabloları şeklinde kodlanır.
- **Analiz Alanları:** Market sepeti analizi, müşteri davranışı, ilişki kuralları madenciliği.
- **Kullanım Alanları:** E-ticaret, pazarlama, biyoinformatik, öneri sistemleri, sosyal ağ analizleri.

METİN VERİLERİ (TEXT DATA)

Metin Verileri, doğal dilde yazılmış, yapısal biçimi bulunmayan ve anlamın kelime dizilimleriyle taşındığı veri türüdür. Bu veriler genellikle belgeler, e-postalar, sosyal medya paylaşımları, haber metinleri veya kullanıcı yorumları gibi kaynaklardan elde edilir. Metin verileri yapısal düzen içermediği için analiz öncesinde temizleme, kök bulma, durak kelime çıkarma ve kelime sıklığı hesaplama gibi ön işleme adımları uygulanır. Bu tür verilerden bilgi çıkarımı için doğal dil işleme (NLP), duygu analizi, konu modelleme ve metin madenciliği gibi yöntemler kullanılır. Örneğin, bir ürün hakkında yapılan müşteri yorumlarının olumlu ya da olumsuz olup olmadığını belirlemek, metin verisi analizine tipik bir örnektir.

- **Yapısal Olmayan Doğa:** Serbest biçimli dil kullanımı nedeniyle düzenli tablo yapısı bulunmaz.
- **Anlamsal Yoğunluk:** Bilgi, kelimeler arası ilişkiler ve bağlam üzerinden taşınır.
- **Ön İşleme Gereksinimi:** Temizleme, durak kelime çıkarma ve kök bulma işlemleri zorunludur.
- **Analiz Yöntemleri:** Doğal dil işleme, duygu analizi, konu modelleme, kelime bulutu analizi.
- **Kullanım Alanları:** Sosyal medya analitiği, müşteri geri bildirimleri, bilgi erişim sistemleri, haber madenciliği.

KARŞILAŞTIRMA

Veri Türü	Tanım	Veri Yapısı	Analiz Yöntemleri	Kullanım Alanları	Örnek
Nicel Çok Boyutlu Veri	Ölçülebilir, sayısal değerlerden oluşan, birden fazla boyuta sahip veri türü.	Tablo veya matris biçiminde; her sütun bir değişkeni temsil eder.	Regresyon, kümeleme, korelasyon analizi, PCA.	Finans, mühendislik, pazarlama, bilimsel araştırmalar.	Yaş–gelir–harcama puanı veri seti.
Kategorik ve Karma Nitelikli Veri	Sınıflara veya etiketlere dayalı, nitel veya karma (nitel+nicel) özellikteki veriler.	Kategorik etiketler, sınıflar veya sayısal kodlamalar.	Karar ağaçları, lojistik regresyon, sınıflandırma.	Sosyoloji, müşteri segmentasyonu, anket analizi.	Cinsiyet (nitel) + Yaş (nicel) değişkenleri.
İkili ve Küme Verisi	Her özniteliğin iki olasılığa sahip olduğu veya birden fazla özelliğin aynı anda bulunduğu veri.	0/1 göstergeli matris veya öğe listeleri.	Birliktelik kuralları, örüntü madenciliği, ilişki analizi.	E-ticaret, biyoinformatik, öneri sistemleri.	Market sepeti: {Ekmek, Süt, Yumurta}.
Metin Verisi	Doğal dilde yazılmış, serbest biçimli yapıya sahip veri türü.	Düz metin, belge, sosyal medya içeriği.	Doğal dil işleme (NLP), duygu analizi, konu modelleme.	Sosyal medya, müşteri yorumları, haber analizi.	Ürün yorumları veya tweet metinleri.

BAĞIMLILIK TEMELLİ VERİLER

Bağımlılık Temelli Veriler, veri nesneleri arasında zaman, sıra, mekân veya bağlantı gibi belirli ilişkilerin bulunduğu veri türlerini ifade eder. Bu verilerde her bir gözlem, diğerleriyle doğrudan ya da dolaylı biçimde bağlantılıdır; dolayısıyla analiz, yalnızca tekil değerler üzerinden değil, veri noktaları arasındaki ilişkiler üzerinden yürütülür. Zaman serileri, mekânsal veriler, ağ verileri ve diziler bu kategoriye girer. Bu tür veriler, dinamik sistemlerin davranışlarını incelemek, örüntüleri belirlemek ve geleceğe yönelik tahminler yapmak açısından büyük önem taşır. Analizinde istatistiksel korelasyon yöntemlerinin yanı sıra zaman serisi modelleme, dizisel analiz, uzamsal analiz ve grafik teorisi temelli teknikler kullanılır.

ZAMAN SERİSİ VERİLERİ (TIME-SERIES DATA)

Zaman Serisi Verileri, belirli aralıklarla zaman boyunca kaydedilen ölçümlerden oluşan veri türüdür. Bu verilerde temel amaç, geçmiş eğilimleri inceleyerek geleceğe dair tahminlerde bulunmaktır. Zaman bağımlılığı, bu veri türünün en belirgin özelliğidir; çünkü her gözlem bir önceki gözleme bağlıdır. Finans, ekonomi, enerji, sağlık ve çevre gibi alanlarda sistemlerin zamana bağlı değişimini analiz etmek için sıklıkla kullanılır. Örneğin, bir enerji şirketinin günlük elektrik tüketim değerlerini kaydetmesi zaman serisi verisine tipik bir örnektir.

- **Zaman Boyutu:** Her veri noktası belirli bir zaman etiketine sahiptir.
- **Bağımlılık İlişkisi:** Gözlemler birbirine bağlıdır; geçmiş değerler geleceği etkiler.
- **Trend ve Mevsimsellik:** Uzun dönemli eğilimler veya dönemsel dalgalanmalar içerir.
- **Analiz Yöntemleri:** ARIMA, hareketli ortalama, üstel düzeltme, LSTM gibi modeller kullanılır.
- **Kullanım Alanları:** Finansal tahminler, hava durumu analizi, enerji talep öngörüsü, üretim planlama.

AYRIK DİZİLER VE KARAKTER DİZİLERİ (DISCRETE SEQUENCES AND STRINGS)

Ayrık Diziler ve Karakter Dizileri, belirli bir sıraya sahip olaylar, semboller veya karakterlerden oluşan veri türleridir. Bu verilerde gözlemler ardışık biçimde düzenlenmiştir ve her bir öğenin anlamı, dizideki konumuna bağlıdır. Sıralı yapısı sayesinde örüntü tanıma, sıralama tahmini ve dizisel benzerlik analizleri yapılabilir. Genellikle biyoinformatik, metin madenciliği, kullanıcı davranışı analizi ve web tıklama akışı gibi alanlarda kullanılır. Örneğin, bir kullanıcının bir web sitesinde ziyaret ettiği sayfaların sırasını analiz etmek ayrık diziler ve karakter dizileri verisine örnektir.

- **Sıralı Yapı:** Her veri öğesi belirli bir sıra içinde yer alır ve bu sıra anlam taşır.
- **Bağımlılık Özelliği:** Önceki öğeler sonraki öğelerin analizinde belirleyici rol oynar.
- **Veri Formatı:** Harf, sayı, sembol veya olay sırası biçiminde temsil edilir.
- **Analiz Yöntemleri:** Örüntü madenciliği, dizi hizalama, Markov modelleri.
- **Kullanım Alanları:** DNA dizileri, metin analizi, kullanıcı gezinme akışı, işlem sıraları.

MEKÂNSAL VERİLER (SPATIAL DATA)

Mekânsal Veriler, nesnelerin konum, şekil, boyut ve uzamsal ilişkilerini ifade eden veri türleridir. Bu veriler, yalnızca değerleriyle değil, aynı zamanda birbirlerine göre konumlarıyla da anlam taşır. Mekânsal veri analizi, coğrafi olayları, dağılımları ve mekânsal örüntüleri inceleyerek yer temelli karar süreçlerine katkı sağlar. Bu veri türü, şehir planlamasından çevre izlemeye kadar birçok alanda kullanılır ve genellikle Coğrafi Bilgi Sistemleri (GIS) üzerinde görselleştirilir. Örneğin, bir şehirdeki okul, hastane ve parkların koordinatlarının analiz edilmesi mekânsal veri kullanımına tipik bir örnektir.

- **Konumsal Doğa:** Her veri nesnesi bir koordinat (x, y, z) ya da coğrafi konumla tanımlanır.
- **Uzamsal İlişki:** Veriler arasında mesafe, yakınlık, komşuluk gibi ilişkiler bulunur.
- **Veri Temsili:** Nokta, çizgi, çokgen (poligon) veya raster biçiminde temsil edilir.
- **Analiz Yöntemleri:** Uzamsal istatistik, jeo-analiz, sıcaklık haritaları, mekânsal kümelenme.
- **Kullanım Alanları:** Coğrafi bilgi sistemleri, şehir planlama, çevre yönetimi, afet analizi.

AĞ VE GRAFİK VERİLERİ (NETWORK AND GRAPH DATA)

Ağ ve Grafik Verileri, nesneler arasındaki ilişkileri düğümler (node) ve bağlantılar (edge) aracılığıyla temsil eden, yapısal özellikler taşıyan veri türleridir. Bu veriler genellikle sosyal ağlar, biyolojik etkileşim ağları, ulaşım sistemleri veya tavsiye sistemleri gibi ilişki tabanlı ortamlardan elde edilir. Verinin anlamı sadece tekil öğelerde değil, bu öğeler arasındaki bağlantıların yapısında da gizlidir. Analiz sürecinde düğüm derecesi, komşuluk, merkezilik ve alt grafik çıkarımı gibi yöntemler kullanılır. Örneğin, sosyal medya ağında kullanıcıların arkadaşlık ilişkileri incelenerek, bilgi yayılımı veya etki alanı analiz edilebilir.

- **Yapısal Olmayan Doğa:** Serbest biçimli dil kullanımı nedeniyle düzenli tablo yapısı bulunmaz.
- **Anlamsal Yoğunluk:** Bilgi, kelimeler arası ilişkiler ve bağlam üzerinden taşınır.
- **Ön İşleme Gereksinimi:** Temizleme, durak kelime çıkarma ve kök bulma işlemleri zorunludur.
- **Analiz Yöntemleri:** Doğal dil işleme, duygu analizi, konu modelleme, kelime bulutu analizi.
- **Kullanım Alanları:** Sosyal medya analitiği, müşteri geri bildirimleri, bilgi erişim sistemleri, haber madenciliği.

KARŞILAŞTIRMA

Veri Türü	Tanım	Veri Yapısı	Analiz Yöntemleri	Kullanım Alanları	Örnek
Zaman Serisi Verileri	Belirli zaman aralıklarında toplanan, geçmiş eğilimlere göre geleceği öngörmeye yarayan veriler.	Zaman etiketli sayısal diziler (tarih–değer çiftleri).	ARIMA, hareketli ortalama, üstel düzeltme, LSTM.	Finans, enerji, hava durumu, üretim planlama..	Günlük elektrik tüketim değerleri.
Ayrık Diziler ve Karakter Dizileri	Belirli sıraya sahip olay veya sembol dizilerinden oluşan veriler.	Sıralı olay dizileri veya karakter dizileri (sequence).	Örüntü madenciliği, Markov modelleri, dizi hizalama.	Biyoinformatik, web gezinme analizi, metin madenciliği..	Kullanıcının web sayfası ziyaret sırası.
Mekânsal Veriler	Nesnelerin konum, şekil ve uzamsal ilişkilerini ifade eden veriler.	Nokta, çizgi, poligon veya raster biçimli coğrafi veriler.	Uzamsal istatistik, jeo-analiz, kümelenme, sıcaklık haritaları.	Şehir planlama, çevre yönetimi, afet analizi.	Şehirdeki hastane ve okul koordinatları.
Ağ ve Grafik Verileri	Nesneler ve aralarındaki ilişkilerden oluşan veri yapısı.	Düğüm–bağlantı (node–edge) biçiminde grafik modeli.	Sosyal ağ analizi, bağlantı madenciliği, grafik teorisi.	Sosyal medya, iletişim ağları, web bağlantıları.	Kullanıcılar arasındaki arkadaşlık ilişkileri.

BİÇİMSEL SINIFLANDIRMA

Veri yapısallığı, verinin nasıl organize edildiğini, depolandığını ve yorumlandığını belirleyen biçimsel düzen düzeyidir. Bir verinin yapısal olup olmaması, onun analitik süreçte nasıl işleneceğini ve hangi araçlarla analiz edileceğini doğrudan etkiler. Yapısal veri belirli bir formata sahip olduğu için bilgisayar sistemleri tarafından kolayca işlenebilirken, yapısal olmayan veri serbest biçimli yapısıyla daha fazla ön işleme ve yorumlama gerektirir. Bu nedenle veri yapısallığı, veri bilimi projelerinde doğru analiz yönteminin seçilmesi açısından temel bir belirleyicidir.

Veri yapısallığı aynı zamanda veri yönetim stratejilerinin temelini oluşturur. Kurumlar, verilerini toplarken hangi türde olduklarını bilirlerse depolama, erişim ve güvenlik sistemlerini buna göre planlayabilirler. Günümüzde sensörlerden gelen akış verileri, sosyal medya paylaşımları, metin belgeleri ve kurumsal tablolar gibi çok farklı veri biçimleri aynı ekosistemde bulunur. Bu çeşitlilik, veri analistlerini yapısal, yarı yapısal ve yapısal olmayan veriler arasında doğru ayrımı yapmaya ve her birine uygun dönüştürme, temizleme ve analiz teknikleri geliştirmeye yönlendirir.

YAPILANDIRILMIŞ VERİLER

Yapılandırılmış Veriler, belirli bir şemaya göre düzenlenmiş, satır–sütun yapısına sahip verilerden oluşur. Bu veriler, bilgisayar sistemleri tarafından kolayca okunabilir, depolanabilir ve analiz edilebilir niteliktedir. Her sütun belirli bir özniteliği, her satır ise bir kayıt veya gözlemi temsil eder. Düzenli yapısı sayesinde sorgulama, filtreleme ve istatistiksel analiz işlemleri hızlı biçimde yapılabilir. Örneğin, bir banka veri tabanındaki müşteri bilgileri tablosu (ad, yaş, bakiye, şehir) yapılandırılmış veriye tipik bir örnektir.

- **Düzenli Şema:** Veriler önceden tanımlanmış bir tablo yapısına sahiptir.
- **Sorgulanabilirlik:** SQL gibi dillerle doğrudan erişim ve analiz mümkündür.
- **Tutarlılık:** Her sütun belirli bir veri türü (sayı, metin, tarih vb.) içerir.
- **Depolama:** Genellikle ilişkisel veri tabanlarında (RDBMS) saklanır.
- **Kullanım Alanları:** Finans, müşteri yönetimi, kurumsal raporlama, insan kaynakları.

YARI YAPILANDIRILMIŞ VERİLER

Yarı Yapılandırılmış Veriler, tamamen düzenli bir tablo yapısına sahip olmayan, ancak belirli bir etiketleme veya hiyerarşik düzene göre organize edilmiş veri türleridir. Bu veriler, yapılandırılmış verilerin düzenliliği ile yapılandırılmamış verilerin esnekliğini birleştirir. Bilgi genellikle anahtar–değer çiftleri, etiketler veya ağaç yapıları aracılığıyla temsil edilir. Bu sayede hem insanlar hem bilgisayarlar tarafından okunabilir ve sistemler arası veri paylaşımı kolaylaşır. Örneğin, bir web API'sinden alınan JSON biçimindeki kullanıcı verisi (ad, yaş, e-posta) yarı yapısal veriye tipik bir örnektir.

- **Esnek Yapı:** Veriler belirli bir şema izler ancak tablo biçiminde değildir.
- **Etiketleme Sistemi:** Bilgi XML, JSON veya YAML gibi biçimlerde tanımlayıcı etiketlerle saklanır.
- **Okunabilirlik:** Hem insanlar hem makineler tarafından kolayca yorumlanabilir.
- **Depolama:** NoSQL veri tabanlarında veya belge tabanlı sistemlerde tutulur.
- **Kullanım Alanları:** Web servisleri (API), IoT cihaz verileri, e-posta sistemleri, veri entegrasyonu.

YAPILANDIRILMAMIŞ VERİLER

Yapılandırılmamış Veriler, belirli bir şemaya veya tablo düzenine sahip olmayan, serbest biçimli verilerden oluşur. Bu veriler, metin, ses, görüntü, video veya sosyal medya içerikleri gibi farklı biçimlerde olabilir. Yapısal düzenin olmaması, bu verilerin doğrudan analizini zorlaştırır; bu nedenle metin madenciliği, doğal dil işleme (NLP) ve yapay zekâ tabanlı yöntemlerle işlenir. Büyük veri analitiği alanında önemli bir yere sahiptir, çünkü günümüzde üretilen verilerin büyük çoğunluğu bu türdedir. Örneğin, kullanıcıların sosyal medya paylaşımları, e-posta içerikleri veya müşteri yorumları yapılandırılmamış verilere örnektir.

- **Serbest Biçimli Yapı:** Veriler önceden tanımlı bir şema veya düzen içermez.
- **Çeşitlilik:** Metin, ses, görüntü, video gibi farklı veri türlerini kapsar.
- **Analiz Zorluğu:** İşlenmeden önce temizleme, sınıflandırma ve dönüştürme gerekir.
- **Depolama:** Bulut sistemleri, veri gölleri (data lake) veya dağıtık depolama çözümleri kullanılır.
- **Kullanım Alanları:** Sosyal medya analizi, duygu analizi, görüntü tanıma, müşteri geri bildirim analizi.

KARŞILAŞTIRMA

Veri Türü	Tanım	Veri Yapısı	Analiz Yöntemleri	Depolama Biçimi	Kullanım Alanları	Örnek
Yapılandırılmış Veriler	Belirli bir şemaya göre satır–sütun biçiminde düzenlenmiş veriler.	Tablolar, veri tabanları, matris yapıları.	SQL sorguları, istatistiksel analiz, makine öğrenmesi.	İlişkisel veri tabanları (RDBMS).	Finans, CRM, satış yönetimi, envanter takibi.	Müşteri bilgileri tablosu (ad, yaş, bakiye).
Yarı Yapılandırılmış Veriler	Kısmen düzenli, ancak sabit tablo yapısına sahip olmayan veriler.	Etiketlenmiş metin (JSON, XML, HTML).	Veri ayrıştırma, NoSQL analizi, veri dönüşümü.	NoSQL veya belge tabanlı veri tabanları.	Web API'leri, IoT verileri, e-posta sistemleri.	JSON dosyası: {"ad": "Ali", "yaş": 25}.
Yapılandırılmamış Veriler	Sabit bir biçimi olmayan, serbest yapılı veriler.	Metin, ses, görüntü, video, sosyal medya içeriği.	Metin madenciliği, NLP, görüntü/ses analizi, yapay zekâ.	Veri gölleri (Data Lake), bulut depolama sistemleri.	Sosyal medya, medya analitiği, duygu analizi.	Tweet içerikleri, e-posta mesajları, video kayıtları.

VERİ KAYNAKLARI

Veri kaynakları; veri analitiği sürecinin başlangıç noktasını oluşturan, ham bilgilerin elde edildiği ortamlardır. Günümüzde veri yalnızca kurum içi sistemlerden değil; sensörlerden, sosyal medyadan, kamuya açık platformlardan ve dijital cihazlardan da sürekli olarak üretilmektedir. Bu nedenle veri kaynaklarının çeşitliliği, analiz edilecek bilginin zenginliğini ve kapsamını doğrudan belirler. Kaynağın türü; verinin güvenilirliğini, doğruluğunu, güncelliğini ve analizde kullanılacak yöntemi etkiler.

Veri kaynaklarının doğru biçimde tanımlanması, analiz sürecinin kalitesini doğrudan belirleyen temel bir adımdır. Her kaynağın sahip olduğu veri türü, formatı ve güncellenme sıklığı kullanılacak analitik yöntemin ve teknolojik altyapının seçimini etkiler. Bu nedenle veri bilimi süreçlerinde, yalnızca verinin miktarına değil, kaynağın güvenilirliğine, sürdürülebilirliğine ve bağlamsal uygunluğuna da odaklanmak gerekir.

VERİ KAYNAKLARI (SINIFLANDIRMA ŞEMASI)

- **Birincil Veriler**
  - Anket Verileri
  - Görüşme Verileri
  - Gözlem Verileri
  - Deneysel Veriler
  - Saha Ölçümleri
- **İkincil Veriler**
  - **Kurum İçi Veriler**
    - Müşteri Verileri
    - Finansal Veriler
    - Operasyonel Veriler
    - Pazarlama Verileri
    - Çalışan Verileri
    - Üretim Verileri
  - **Kurum Dışı Veriler**
    - Kamu Verileri
    - Web Kazıma Verileri
    - Açık Veriler
    - IoT Verileri
    - Sosyal Medya Verileri
    - İş Ortağı Verileri

BİRİNCİL VERİLER

Birincil Veriler, araştırmacı veya kurum tarafından doğrudan toplanan özgün verilerdir. Bu veriler, belirli bir araştırma amacına yönelik olarak tasarlanır ve toplandıkları anda güncel olma özelliği taşırlar. Doğrudan gözlem, ölçüm veya etkileşim yoluyla elde edildikleri için genellikle yüksek güvenilirlik düzeyine sahiptirler. Ancak zaman, maliyet ve erişim açısından ikincil verilere göre daha fazla kaynak gerektirirler.

- **Anket Verileri:** Belirli bir konuda geniş kitlelerden bilgi toplamak için yapılandırılmış sorularla uygulanır. Nicel analizlerde en sık kullanılan yöntemlerden biridir.
- **Görüşme Verileri:** Katılımcılardan derinlemesine bilgi almak amacıyla birebir veya grup olarak gerçekleştirilir. Özellikle nitel veri analizi ve sosyal araştırmalarda kullanılır.
- **Gözlem Verileri:** Bireylerin, süreçlerin veya olayların doğal ortamlarında sistematik biçimde incelenmesidir. Nesnel veri toplama imkânı sunar, ancak gözlemcinin yorumuna bağlı öznellik riski taşır.
- **Deneysel Veriler:** Kontrollü koşullar altında belirli değişkenlerin etkilerini test etmek amacıyla toplanır. Bilimsel araştırmalarda neden-sonuç ilişkisini belirlemede en güçlü yöntemdir.
- **Saha Ölçümleri:** Gerçek ortamda fiziksel veya çevresel değişkenlerin doğrudan ölçülmesiyle elde edilir. Özellikle mühendislik, çevre bilimi ve IoT uygulamalarında önem taşır.

İKİNCİL VERİLER

İkincil Veriler, daha önce farklı bir amaçla toplanmış, mevcut kaynaklardan elde edilen ve yeniden analiz için kullanılan verilerdir. Bu tür veriler, zaman ve maliyet açısından avantaj sağlar çünkü araştırmacı doğrudan veri toplama sürecine dahil olmaz. Ancak verinin kapsamı, doğruluğu veya güncelliği araştırmanın gereksinimleriyle her zaman tam olarak örtüşmeyebilir. Buna rağmen, büyük veri analitiği ve karar destek sistemlerinde ikincil veriler en yaygın kullanılan kaynaklardır.

Kurum İçi Veriler

Kurumun kendi operasyonları, sistemleri ve süreçlerinden üretilen verilerdir. Bu veriler genellikle düzenli olarak kaydedilir ve karar destek sistemlerinde doğrudan kullanılabilir. Kurum içi veriler, organizasyonun performansını değerlendirmek ve stratejik kararlar almak için en güvenilir kaynaklardan biridir.

- **Müşteri Verileri:** Satın alma geçmişi, tercihleri ve geri bildirimleri gibi müşteri ilişkilerinden elde edilir. Pazarlama analitiği ve müşteri davranışı tahminlerinde önemli rol oynar.
- **Operasyonel Veriler:** Günlük iş süreçlerinden, üretimden ve hizmet operasyonlarından elde edilen verilerdir. Süreç optimizasyonu ve verimlilik analizlerinde kullanılır.
- **Çalışan Verileri:** İnsan kaynakları sistemlerinden gelen demografik, performans ve memnuniyet verileridir. Kurumsal kültür analizi ve insan kaynakları planlamasında kullanılır.
- **Finansal Veriler:** Gelir, gider, kâr, bütçe ve mali raporlar gibi sayısal verilerdir. Kurumun mali performansını ve sürdürülebilirliğini izlemek için temel kaynaktır.
- **Pazarlama Verileri:** Kampanya performansları, reklam harcamaları ve müşteri etkileşimleriyle ilgilidir. Marka yönetimi ve hedef kitle stratejilerinin geliştirilmesinde kullanılır.
- **Üretim Verileri:** Üretim hatlarından, makinelerden veya IoT sensörlerinden elde edilen operasyonel verilerdir. Kalite kontrolü, bakım planlaması ve kaynak tahsisi gibi analizlerde kullanılır.

Kurum Dışı Veriler

Kurumun dış çevresinden, kamuya açık veya ticari kaynaklardan elde edilen verilerdir. Bu veriler genellikle farklı sektörlerden, kurumlar arası iş birliklerinden veya dijital platformlardan sağlanır. Kurum dışı veriler, kurum içi verilerle bütünleştirildiğinde rekabet analizi, pazar tahmini ve stratejik karar destek süreçlerine değer katar.

- **Kamu Verileri:** Devlet kurumları ve istatistik ofisleri tarafından yayınlanan resmi veriler. Ekonomik, demografik ve toplumsal analizlerde sıkça kullanılır.
- **Açık Veriler:** Herkesin erişimine açık, genellikle ücretsiz paylaşılan veri setleridir. Yenilikçi uygulamalar ve akademik araştırmalar için önemli bir kaynaktır.
- **Sosyal Medya Verileri:** Kullanıcı etkileşimleri, yorumlar, beğeniler ve paylaşımlardan oluşur. Marka algısı, duygu analizi ve kullanıcı davranışı tahminlerinde kullanılır.
- **Web Kazıma Verileri:** İnternet sitelerinden otomatik araçlarla toplanan verilerdir. Fiyat karşılaştırma, rekabet analizi ve içerik trendi izleme gibi alanlarda kullanılır.
- **IoT Verileri:** Akıllı cihazlar, sensörler ve bağlı sistemlerden gerçek zamanlı olarak toplanır. Akıllı şehirler, enerji yönetimi ve endüstri 4.0 uygulamalarında kullanılır.
- **İş Ortağı Verileri:** Tedarikçiler, bayiler veya diğer stratejik ortaklarla paylaşılan verilerdir. Tedarik zinciri yönetimi ve iş birliği analitiği için önemlidir.

KARŞILAŞTIRMA

Veri Türü	Tanım	Kaynak	Amaca Uygunluk	Veri Kalitesi	Toplama Süresi ve Maliyeti	Erişim Kolaylığı	Kontrol Düzeyi	Kapsam	Kullanım Alanları
Birincil Veriler	Araştırmacı veya kurum tarafından belirli bir amaçla doğrudan toplanan özgün verilerdir.	Gözlem, anket, görüşme, deney, saha ölçümü.	Tamamen araştırmanın hedeflerine göre tasarlanır.	Güncel, özgün, doğruluğu yüksektir.	Zaman alıcı ve maliyetlidir.	Erişim sınırlı olabilir, doğrudan katılım gerekir.	Veri toplama süreci araştırmacı kontrolündedir.	Spesifik konulara odaklanır.	Akademik araştırmalar, deneysel çalışmalar, müşteri analizleri.
İkincil Veriler	Daha önce farklı bir amaç için toplanmış mevcut verilerdir.	Kurumsal veri tabanları, raporlar, açık veri setleri, kamu istatistikleri.	Yeni araştırma amacına kısmen uygundur.	Kalitesi kaynağa ve güncelliğe bağlıdır.	Hızlı elde edilir, maliyeti düşüktür.	Çoğunlukla kolay erişilebilir (dijital ortamlarda).	Veri içeriği üzerinde kontrol sınırlıdır.	Daha geniş, tarihsel ve çok boyutlu veri içerir.	Pazar araştırmaları, büyük veri analitiği, trend analizi.

UYGULAMA

Size vereceğim kriterler (veri kaynağı, sınıflandırma, veri türü, veri analitiği) doğrultusunda 10 verilik bir veri seti hazırlayıp VEBB Piramidi oluşturacağız.

Veri Kaynağı	**Sınıflandırma**	**Veri Türü**	**Veri Analitiği**	**VEBB Piramidi**
İkincil Veri - Kurum Dışı - Kamu Verileri (Hava Durumu)	Yapısal (Düzenlenmiş)	Metin (Güneşli, Bulutlu, Yağışlı vb.)	Tanısal (Yarın yağmur yağma olasılığı nedir?)	• **Veri:** Günlük sıcaklık kayıtları • **Bilgi:** Sıcaklıklar hafta boyunca ortalama 28°C • **İçgörü:** Sıcak hava trafik kazalarını artırıyor olabilir • **Bilgelik:** Yaz aylarında yol bakım ve sulama planlaması sabah erken saatlere alınmalıdır

---

ÖZET

- Verinin yapısal özelliklerinden kaynak çeşitliliğine uzanan çok katmanlı bir yapı incelendi.
- Başlangıçta veri türlerinin temel sınıflandırması ele alınarak, yapısal, yarı yapısal ve yapısal olmayan veri biçimleri arasındaki farklar açıklandı.
- Ardından, bağımlılık temelli ve bağımlılık temelli olmayan veriler açıklanarak, zaman serileri, metin verileri ve çok boyutlu nicel verilerin analitik kullanımı değerlendirildi.
- Sonraki aşamada veri türlerinin özellikleri, avantajları ve sınırlılıkları karşılaştırmalı olarak ele alındı; hangi veri yapısının hangi analiz yöntemlerine uygun olduğu vurgulandı.
- Devamında veri kaynakları kavramı incelenerek, kurum içi sistemlerden sosyal medya, sensör ağları ve açık veri portallarına kadar uzanan geniş veri ekosistemi tanıtıldı.
- Bu kapsamda, birincil ve ikincil veri ayrımı üzerinde durularak doğrudan toplanan verilerle mevcut kaynaklardan elde edilen verilerin analitik farkları tartışıldı.
- Son olarak, veri kaynaklarının güvenilirlik, güncellik ve bütünleştirilebilirlik açısından değerlendirilmesiyle veri kalitesinin analitik süreçteki kritik rolü vurgulandı.